

# **Notes on Haskell Debugging**



Felis sap... 🚓



函数式编程、编程语言、编程 话题的优秀回答者

已关注

圆角骑士魔理沙、祖与占、题叶、酿酿酿酿酿泉、草莓大福等 57 人赞了该文章

本文是 Deep Dark Haskell 系列的第二集(前作),汇总一下我所知道的所有 Haskell debugging 方法和注意事项。有一部分是跟 profiling 相关的,不过性能问题也是问题嘛,就一 块算在内了。

# 使用条件编译

传统 C/C++ 项目中常见的一个 idiom 是使用宏来区分 debug/release 代码。通过修改编译选 项,即可激活/关闭 debug 相关的 code path (比如各种 pre/post condition 的 assert 等)。 在 Haskell 中也可以这样做。

一个例子是 vector,它在 Cabal 配置中提供一系列 flag,对应不同的 check (比如 bound check) ,可以在 Cabal 的 configure 阶段决定是否打开,而在 vector 的源代码中包含了对应检 查的 C 预处理器宏。对于依赖 vector 的项目而言,在经过充分测试,有信心不会产生 out-ofbound 等错误之后,发布 release 版本的 binary 时,即可将 vector 中所有的 check flag 关掉以 保证性能。

另外,Haskell 提供了原生的 assert,在 ghc 编译选项中带 -O 时会自动关闭。

# 关于 logging

不论语言,一个很原始也很有用的 debugging 手段就是打日志。Haskell 中应用最广的 logging 框架是 fast-logger 和 monad-logger, 前者实现了针对多核运行时优化的 logging, 后者则在 前者基础上实现了 mtl-style 的 MonadLogger class,可以很方便地在 mtl stack 中增加





默认支持的 logging 后端是 stdout 或者文本文件,不过 fast-logger 和 monad-logger 中我们都可以接上自己的后端,比如用 redis 专门做日志服务器。

# 关于 trace 和 unsafePerformIO

在 Haskell 中,IO 类型是带传染性的,这使得一般的 print 调试法用起来不那么方便:如果临时起意需要在纯函数中输出一点东西,却不想让函数被 IO 类型玷污,怎么办?可以使用 trace,其作用是被求值时输出一段 String 并返回原来的参数。trace 的实现基于 unsafePerformIO,其类型签名说明了一切: IO a -> a,能够让一段假装自己 pure 的代码执行任意 IO action。除了debugging 的以外,有许多场合(比如优化性能、实现全局变量、etc)也用到了这个组合子。

trace、unsafePerformIO 等组合子的存在说明 Haskell 的所谓类型安全、引用透明等特性实际上只是一个君子协定而已——能玩坏她的手段还不只于此。为了安全地使用这类在 pure code 中嵌入 IO action 的组合子,需要对 Haskell 的编译和运行机制有一些基本了解,避免一些陷阱:

- 嵌入了 unsafePerformIO 的 pure code, 在 ghc 的眼中与同类型的 pure code 别无二致,而 ghc 针对一般的 pure code 有许多优化措施: inlining、let-floating 等等,这使得假装 pure 的 IO action 执行时机可能与我们期望的相左——inlining 使 IO 可能被重复执行,而 let-floating 使 IO 可能被只执行一次。所以应该尽量将此类代码集中到少数 module 中,使用OPTIONS\_GHC pragma 单独增加编译选项控制优化,使用 NOINLINE pragma 显式禁止 inline,等等。
- Haskell 默认规约策略为 lazy evaluation,一个含 unsafePerformIO 调用的表达式,在被规约 到 WHNF (Weak Head Normal Form) 时,相应的 IO action 才会被执行。至于什么时候一个表达式会被规约到 WHNF 呢?一个不精确的答案是"发生模式匹配时",而精确的答案需要阅读 ghc 的 STG dump 才能确认,后面会提到怎么做。

在有余力实现妥善的 logging 时,请务必用 logging 代替 trace,毕竟为了解决旧的 bug 而引入新的 bug 总是不合算的。

# ghci 断点调试

Haskell 代码的执行方法有 2 种:编译成 object code,作为原生代码链接执行,或编译成 bytecode,通过 ghci 解释执行。如果采用后一种,那么可以使用 ghci 的断点调试功能,设置断点并单步执行。详细方法参考 4.5. The GHCi Debugger。

### 在 Haskell 中获取 call stack

从 ghc 8 开始,我们可以在 Haskell 中获取 call stack 并进行处理。只要在函数类型签名中挂上 HasCallStack constraint,在该函数出错时,出错信息将自动附上 call stack。同时,GHC.Stack 提供了 withFrozenCallStack,可以在我们自己的异常处理代码中冻结当前 call stack 并获取其内





# 阅读 STG dump

ghc 将 Haskell 源代码编译到原生代码的 pipeline 中,经历了多种不同中间表示的转换,可以通过各种 -ddump-xx flag 导出到文本来查看(详细参考 6.13. Debugging the compiler)。阅读这些中间表示可以深入学习 Haskell 的实现原理,同时对调试性能问题很有帮助,比如直接确认一些优化措施是否的确反映到了生成的代码中(inlining、unboxing、let-floating、worker/wrapper 变换,等等)。

在几种中间表示中,推荐阅读 STG。STG 在 ghc pipeline 中发挥承上启下的作用: STG 之前是Core,这是一种带显式类型标注的"精简版" Haskell,而 STG 是特殊形式的 Core,通过 ANF变换将 evaluation 顺序全部显式表明,STG 之后就是 C-like 的 Cmm,此时基本无法看出 Cmm dump 与原始 Haskell 之间的关联。

阅读 STG dump 并不需要许多预备的阅读材料: 先看 How to make a fast curry: push/enter vs eval/apply (ghc 使用 eval/apply 机制), 然后看 GHC API 文档中的 StgSyn 模块里, STG 的 AST 是如何定义的,结合 -ddump-stg 导出的 STG dump 进行阅读。下面是一个简单的例子:

Fact.hs 内容(包含一个简单的阶乘函数)

```
{-# OPTIONS_GHC -Wall -O2 -ddump-to-file -ddump-stg #-}

module Fact where

fact :: Int -> Int
fact 0 = 1
fact n = n * fact (n - 1)
```

运行 ghc Fact.hs 之后, 查看 Fact.dump-stg。其中 fact 相关内容:

```
Fact.$wfact [InlPrag=[0], Occ=LoopBreaker]
:: GHC.Prim.Int# -> GHC.Prim.Int#
[GblId, Arity=1, Caf=NoCafRefs, Str=<S,1*U>, Unf=OtherCon []] =
    \r [ww_s296]
    case ww_s296 of ds_s297 {
        __DEFAULT ->
        case -# [ds_s297 1#] of sat_s298 {
        __DEFAULT ->
        case Fact.$wfact sat_s298 of ww1_s299 {
        __DEFAULT -> *# [ds_s297 ww1_s299];
        };
    };
};
```



结合 StgSyn 的类型定义,可以看出哪些门道呢?

- 与 Core 相比, STG 的 AST 上标注了许多用于 codegen 的额外信息,同时不再保证每个 binder 都带上类型标注;
- 整个 STG program 是一系列 StgTopBinding 的列表;
- 从 GenStgBinding 可以看出,STG 中的 binding 清晰地分为非递归和递归的情形,对应 MLfamily 语言中的 let 和 letrec。所以 Haskell 实际上也是有 letrec 的(摊手
- 一个 binding 将一系列 GenStgRhs 绑定到一系列变量。所以函数定义变成了 lambda 表达式 绑定到函数名的形式;
- 绑定的 right hand side 中,表达式是不能任意嵌套的,我们已经可以从中看出 heap object 的创建和求值时机。比如要将一个函数或者 data constructor 给 apply 到一系列表达式的话,应用对象是 GenStgArg,对应 fast curry paper 中的 atom (literal/variable) ,我们需要通过一系列 nested let 来将表达式绑定到变量,才能 apply。此时,一个 let expression 会创建一个 thunk 所对应的 heap object,将 heap object 的指针往 let expression 内部传递,而一个 case expression 会将一个 thunk 求值到 WHNF;
- case expression 必须是 exhaustive 的,覆盖所有 case。同时第一个 alternative 必须是内置的 DEFAULT,原因是为美观考虑;
- 关于 # 结尾的常量、算符和 data constructor: GHC 的整数分为 boxed/unboxed integer, 后一种就是对应 host platform 上的 machine int, 而前一种则对应有一个 garbage-collected heap object。每个 heap object 的内存布局包含一个指向 info table 的指针以及 payload, 其中 payload 部分保存着原本的 int。所有 kind 为 \* 的 Haskell 类型,在内存中都使用类似的表示方式。# 结尾的常量和算符对应原生的常量和算符,像 -# [ds\_s297 1#] 代表(ds\_s297 1),GHC.Types.l# [ww2\_s29d] 指的是将 ww2\_s29d 代表的 unboxed int 重新装箱,case w\_s29a of { GHC.Types.l# ww1\_s29c ... } 指的是将 w\_s29a 代表的 boxed int 求值到 WHNF,将求值后获得的 unboxed int 绑定到 ww1 s29c 继续之后的计算。
- 源代码中只有一个 fact 函数,这里为什么产生了 \$wfact 这个额外的函数?这是 ghc 中

了,所以 ghc 生成了一个对 unboxed int 进行快速阶乘的函数 \$wfact (worker) ,而原本的 fact 函数只是一个调用 \$wfact,并负责参数与结果的 unboxing/boxing 处理的 wrapper 函数。这样一来,我们需要额外付出的开销只有开始计算时的一次 unboxing 和计算结束时的一次 boxing,中间和 C 是一样快的。为什么不在所有的地方都操作 unboxed 的值?考虑到 ghc 基于 boxing 的编译策略, unboxed 类型值的抽象能力是严重受限的,使用不便。

如果我们把 fact 的类型签名改得更加 polymorphic 一些,我们就能直观地感受到 Haskell 中的抽象并不免费,而伴随着性能开销这件事情了:

```
fact :: (Eq a, Num a) => a -> a
fact 0 = 1
fact n = n * fact (n - 1)
```

#### 生成的 STG 代码:

```
Fact.fact [Occ=LoopBreaker]
  :: forall a. (GHC.Classes.Eq a, GHC.Num.Num a) => a -> a
[GblId,
Arity=3,
Caf=NoCafRefs,
Str=<S(C(C(S))L),U(C(C1(U)),A)><S,U(A,C(C1(U)),C(C1(U)),A,A,A,C(U))><L,U>,
Unf=OtherCon []] =
   \r [$dEq_s2eL $dNum_s2eM ds_s2eN]
        let {
          sat_s2e0 [Occ=Once] :: a_a2cU
          [LclId] =
              \u [] GHC.Num.fromInteger $dNum_s2eM lvl_r2dH;
        } in
          case GHC.Classes.== $dEq_s2eL ds_s2eN sat_s2eO of {
            GHC.Types.False ->
                let {
                  sat_s2eS [Occ=Once] :: a_a2cU
                  [LclId] =
                      \u []
                          let {
                            sat_s2eR [Occ=Once] :: a_a2cU
                            [LclId] =
                                \u []
                                    let {
                                       sat_s2eQ [Occ=Once] :: a_a2cU
                                       [LclId] =
                                           \u [] GHC.Num.fromInteger $dNum_s2eM lvl1_r2
```



```
} in GHC.Num.* $dNum_s2eM ds_s2eN sat_s2eS;
GHC.Types.True -> GHC.Num.fromInteger $dNum_s2eM lvl1_r2eF;
};
```

啊咧咧,没法自动进行 worker/wrapper 优化了。这段 STG 中有意思的地方:为什么 fact 好像多出了两个参数呢?新的两个参数名\$dEq\_s2eL,\$dNum\_s2eM,从名字我们就能猜到是什么了——type class dictionary。GHC 中实现 type class 机制很简单粗暴,dictionary passing,每个 instance 实现都是一个 dictionary (没错,也是 heap object),然后函数参数包含 dictionary 来支持不同 instance。

# 使用 gdb 调试

你没有看错, ghc 编译的原生代码是可以使用 gdb 调试的! 需要记住的几点:

- 编译选项记得带上 -debug -g。-debug 是 linker flag,链接 debugging rts,这个版本的 rts 是单线程的,并且带有更多的 sanity check,包含更多 symbol,方便调试。-g 会启用 DWARF 信息生成,其应用参考 DWARF - GHC
- Haskell 并不使用原生栈和调用约定。STG 编译到 Cmm 时,会使用一系列的虚拟寄存器(见Commentary/Rts/HaskellExecution/Registers GHC),这些寄存器使用 x86/x64 的通用寄存器是存不下的,所以它们实际保存在 BaseReg 结构体中,而 BaseReg 的位置保存在ebx (x86) / r13 (x64) 中。要查看 STG 虚拟寄存器的值,在{GHC\_INSTALL\_DIR}/lib/ghc-{GHC\_VERSION}/include/DerivedConstants.h中可以获取BaseReg 中不同 field 的 offset,然后从 ebx/r13 获取的地址加上 offset 读取即可。
- Haskell 也不直接使用原生 thread,而是先维护一个 thread pool,每个 worker thread 称为 Capability,然后每个 Capability维护一个 Haskell thread 的队列,每个 Haskell thread 对应一个 TSO (Thread State Object),每个 Haskell thread 有独立的栈,对应 STG 栈的一个片段,TSO 中的栈顶指针指向这个片段。调试链接了 threaded runtime 的程序之前,可以从 includes/rts/storage/TSO.h 看起。
- 关于整个 Haskell heap 的内存布局,参考 Commentary/Rts/Storage/HeapObjects GHC

# profiling

Cost-Centre Profiling 是 ghc 内置的 profiling 机制:在 Haskell 源代码中,可以使用 SCC pragma 将一个函数归类到一个 cost centre,然后给运行时传 -p 的选项,即可生成一个 profile 报告,列举每个 cost centre 的运行时间和内存分配数据。使用 -fprof-auto 编译选项,可以给每个函数自动插入 SCC 标记。



COST-CENTIFE 的用速定以别系统中的性能规划。而开划另一种场景——比较问一切能的个问头现 的性能,推荐使用 criterion: a Haskell microbenchmarking library 手动实现,criterion 的特色 功能是自动反复执行 benchmark 并对数据进行统计分析生成报表,增加结果的可靠程度。

# **GHC** eventlogs

ghc 的运行时还有一个 event log 机制,支持记录多种事件(如 gc 触发、线程 / spark 创建、进 程调用等,详见 GHC.RTS.Events)。可以使用 ghc-events 库解析 event log 文件,或者使用 threadscope 可视化查看 event log。在调试 Haskell 程序的空间问题时,event log 非常有用。

编辑于 2017-04-24

「真诚赞赏,手留余香」

赞赏

还没有人赞赏, 快来当第一个赞赏的人吧!

Haskell GHC (编程套件)

函数式编程

▲ 赞同 57

3条评论

7 分享

### 文章被以下专栏收录



#### 不动点高校现充部

-切与编程语言理论、函数式编程相关的杂谈。

已关注

#### 推荐阅读



订想中的Haskell - Compiling

#### 学 Haskell 果然是要趁早

几年前, length 的类型是介个样子 滴length :: [a] -> Int 现在你打 开 GHCi 捏,是介个样子滴, (搜 FTP,并没有真相 length:: Foldable t => t a -> Int 当 然了,这其实并不会...





3 条评论 ➡ 切换为时间排序

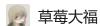
### 写下你的评论...



1年前

虽然卜懂haskell, 但是封面很好





1年前

求 Reference (厚脸求



🥌 Felis sapiens (作者) 回复 草莓大福

1年前

主要就是 ghc commentary 和文档

┢ 赞 ● 查看对话